



Auditeur de Cohérence Médicale

Solution d'intelligence artificielle multimodale et chaîne MLOps de bout en bout : entraînement, déploiement, monitoring et réentraînement automatisé.

Bloc 4 - Construire, déployer et piloter des solutions d'IA

Aïcha FATHELLAH


Contexte et objectif

Le besoin métier

En imagerie médicale, une radiographie thoracique peut être associée par erreur au compte rendu d'un autre patient. Cette incohérence documentaire constitue un risque pour la sécurité des soins et pour la fiabilité des dossiers.

La solution

Un outil d'audit qui reçoit une paire image-texte et estime la probabilité qu'elle décrive le même examen. Il signale les associations incohérentes pour une revue humaine. Il ne pose pas de diagnostic.



Le modèle : classification binaire multimodale


Architecture fondée sur BioViL-T (encodeurs image et texte spécialisés pour la radiographie thoracique, licence publique MIT), surmontée d'un classifieur à attention croisée où le texte interroge les régions de l'image.



Caractéristiques techniques

- Jeu d'entraînement : 20 000 paires équilibrées (10 000 cohérentes, 10 000 incohérentes) issues de CheXpert.
- Optimiseur AdamW, perte BCE, arrêt anticipé ; réglages repris du notebook d'origine (lot 64, 100 époques maximum).
- Performance obtenue : environ 89 % d'exactitude de validation.

Architecture de la chaîne MLOps




La boucle de production est automatisée. L'application de démonstration embarque son propre modèle et alimente le datalake ; l'API constitue le composant de production relié au registre MLflow. Les deux jouent des rôles distincts.

La boucle de réentraînement automatisée

- 1 L'application journalise ses prédictions et les embeddings sémantiques associés dans le datalake Azure Blob Storage.
- 2 Un workflow planifié (GitHub Actions) mesure quotidiennement la dérive sémantique avec Evidently.
- 3 Au-delà du seuil de 0,55, un signal de type repository_dispatch est émis vers le dépôt du projet.
- 4 Ce signal déclenche le workflow de réentraînement, qui relance l'entraînement sur Kaggle via son API.
- 5 Le modèle est journalisé dans MLflow, enregistré au registre et promu en production s'il améliore la perte de validation.
- 6 L'API recharge le modèle de production sans interruption de service, via sa route dédiée /reload-model.

Architecture technique détaillée

Architecture MLOps - Auditeur de Cohérence Médicale



Vue complète de l'infrastructure : cloud (MLflow, Neon, Azure Blob Storage, registre de modèles), entraînement sur Kaggle, service de prédiction (API FastAPI), surveillance (Evidently) et orchestration par GitHub Actions.

Gestion des versions et promotion contrôlée

Promotion manuelle


Après un réentraînement, un intervenant humain décide de mettre le nouveau modèle en production. Aucune vérification automatique ne garantit qu'il soit supérieur au modèle en place.

Promotion conditionnelle automatisée

Le nouveau modèle reçoit l'alias production uniquement si sa perte de validation est inférieure à celle du modèle en place. La comparaison est automatique et prévient toute régression. Le retour arrière consiste à repositionner l'alias sur une version antérieure.

Vérification en conditions réelles : un réentraînement produisant une perte de validation de 0,30 a été écarté automatiquement, la version en production affichant une perte inférieure (0,28). Le modèle en place a été conservé.

Démonstration



Cas cohérent

vraie paire, verdict COHÉRENT, 91,8 %

Cas incohérent

compte rendu d'un autre examen, écarté

Application en ligne :

huggingface.co/spaces/AichaFaHugFace/Auditeur-App-Gradio

Code source et vidéo : github.com/AichaFa/projet_final_ACM

La démonstration s'appuie sur le modèle initial embarqué dans l'application ; la boucle de réentraînement produit et gère les versions suivantes dans le registre MLflow.

Résultats et couverture fonctionnelle

89 %

exactitude de validation du
modèle

20 000

paires d'entraînement équilibrées

91,8 %

confiance sur la vraie paire en
démonstration

0,55

seuil de dérive déclenchant le
réentraînement

Couverture fonctionnelle

Entraînement et suivi d'expériences (MLflow), registre de modèles versionné avec promotion conditionnelle, exposition par API REST conteneurisée (FastAPI, Docker), intégration continue (GitHub Actions), monitoring de dérive (Evidently) et réentraînement automatisé.

Perspectives d'industrialisation



Sécurisation du serveur MLflow

Ajout d'une authentification (mécanisme natif MLflow ou passerelle d'identité du fournisseur cloud), avec gestion des identifiants par secrets.



Convergence de la ressource de calcul

Migration du calcul GPU, aujourd'hui déporté sur Kaggle, vers une ressource intégrée au cloud de production lorsque le quota le permettra.



Alerte active sur dérive

Notification par courriel ou webhook en complément des rapports de dérive archivés, pour un pilotage proactif.

Une chaîne MLOps complète couvrant l'ensemble du cycle de vie du modèle, de l'entraînement au réentraînement automatisé.